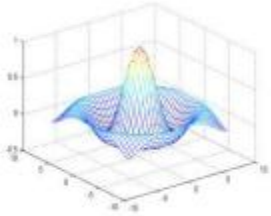
2024 年高斯杯数学建模联赛



题 目 数据驱动的光伏发电功率预测

摘 要

随着全球对可再生能源需求的持续增长，光伏发电作为一种高效、清洁且可持续的能源形式，正逐步成为现代能源结构中的关键组成部分。光伏发电通过将太阳能直接转化为电能，在降低碳排放和减少对传统化石能源依赖方面发挥着重要作用。然而，光伏发电的实际输出功率受到多种环境因素的影响，如太阳辐射强度、温度、风速等，这些因素导致发电功率具有显著的波动性。如何准确预测光伏发电功率，以便优化电网系统、提高能源利用效率并保障光伏发电稳定运行成为本次研究的首要问题。

本文旨在通过应用数学模型和多种算法对光伏发电功率进行精准预测，以应对上述问题。本文首先系统地分析了对光伏发电功率影响最大的因素，评估了各因素对光伏发电功率的影响程度，为后续模型的选择应用提供了重要的数据支持，同时也有助于模型在预测过程中抓住主要影响因素，从而提升预测精度。

在算法选择方面，本文探讨了多种预测模型的构建，包括传统的统计模型，如线性回归，以及先进的机器学习算法，例如随机森林（Random Forest）、支持向量机（SVM）和决策树（Decision Tree）。不同算法在处理大量光伏发电数据时各有利弊，本文通过对比分析以上算法模型的呈现结果，选择最适合当前数据特点的模型，以进一步提升预测结果的精度和稳健性。模型构建完成后，本文采用了多种评价指标对模型的性能进行系统误差分析。这些指标包括均方误差（MSE）、均方根误差（RMSE）、平均绝对误差（MAE）和决定系数（R^2）等，这些指标能够从不同角度衡量模型的预测误差和拟合效果。鉴于光伏发电预测的实际应用需求，本文特别关注了模型在不同条件下的表现，尤其是其在极端天气条件下的稳健性。此外，本文还分析了预测误差的来源，探讨了通过改进模型结构或数据预处理技术来减少误差的可能性。

通过以上研究，本文不仅为光伏发电功率的精准预测提供了理论和方法支持，还为电网系统、能源应用的提升以及光伏发电的高效运行提供了研究方向。结果表明，精确的光伏功率预测模型可以显著提高能的利用效率，减少因预测误差导致的能源浪费。

关键词：随机森林 决策树 支持向量机 线性回归 光伏发电

目录

一、问题重述.....1
二、问题分析.....1
三、基本假设.....2
四、符号说明.....2
五、模型建立与求解.....3
5.1问题一的分析与求解.....3
5.1.1原始数据集加载.....3
5. 1. 2 数据清洗.....3
5.1.3时间特征提取.....5
5.1.4 特征工程：影响因素的定量分析与选择.....5
5.2问题二的分析与求解（模型构建）.....8
5.2.1模型选择与构建.....8
5. 2. 2模型训练与验证.....8
5.3问题三的分析与求解.....10
六、模型评价与应用.....11
6.1模型的优点.....11
6.2模型的缺点以及改进方向.....11
6.3模型的推广与应用(待查资料).....12
七、参考文献.....12
八、附录（代码）.....13

一、问题重述

伴随着可再生能源在全球范围下的需求增长，光伏发电作为一种高效的清洁能源，正在逐渐成为能源结构中不可或缺的组成部分。然而，光伏发电的效率受到多种环境因素的影响，导致其实际输出功率具有显著的波动性和不确定性【1】。本论文旨在通过构建模型，利用所提供的数据资源，建立一个准确的光伏发电功率预测模型。该模型将对电网调度、能源管理以及光伏电站的运维提供预测支持，从而提高整个能源系统的稳定性和效率。

本论文将建立机器学习模型解决以下几个问题：

问题一，影响因素分析：评估并量化不同因素对光伏发电功率的具体影响程度，识别对发电效率具有显著影响的关键变量。

问题二，预测模型构建：探索并实现多种机器学习算法，构建适应不同条件和需求的光伏发电功率预测模型。

问题三，模型评估与优化：选择恰当的评价指标对所构建的预测模型进行综合误差分析，确定最具预测性能的模型。

二、问题分析

考虑到数据量较大，本研究首先进行了数据预处理与探索性数据分析。数据预处理包括缺失值、异常值的检测与处理。对于日降雨量和光伏发电功率这两列数据，考虑到降雨量可能为零，以及在无光照条件下光伏发电无法进行，本研究选择用 0 填充这些列的缺失值。对于数据集中的其他列缺失值，通过计算相应列的均值来填充，以保持数据的完整性。本研究基于数据属性的合理性对异常值进行了识别。例如，风向属性的取值范围应限定在 0 到 360 度之间，其余属性取值应为非负。同时，本研究利用四分位数法（IQR）进一步识别异常值。该方法认为在一个正态分布的数据集中，大部分数据（约 68%）会落在第一四分位数和第三四分位数之间。因此，超出这个范围的数据点被认为是异常的【2】。对于所有识别出的异常值，本研究采取了删除处理，以确保数据集的准确性和可靠性。

探索性数据分析（Exploratory Data Analysis，简称 EDA）是一种数据分析方法，旨在通过可视化手段和简单的统计技术来探索数据集的特征和结构【3】。本研究通过作图、制表、计算简单统计量等多种手段探索光伏发电的数据集，这些方法有助于掌握数据集的基本特点，为后续的深入分析奠定了基础。

针对问题一，光伏发电的输出功率受到多种因素的共同作用。首先，太阳辐射强度是决定光伏发电效率的核心因素，它直接影响光伏电池的电能输出。其次，温度变化也对光伏发电有显著影响，高温通常会降低光伏电池的效率【4】。此外，诸如云层覆盖、湿度、风速、空气污染等环境因素，以及光伏组件的朝向、倾斜角度和遮挡情况，也都会对发电功率产生影响。因此，在建立预测模型之前，必须系统性地分析各个因素对光伏发电功率的影响程度，确定其重要性和相关性。这将有助于模型在预测过程中抓住主要影响因素，从而提高预测的准确性。

针对问题二，光伏发电功率的波动性和不确定性要求预测模型既要具有较

强的适应性，也要能够处理复杂的非线性关系。因此，选择合适的算法对预测结果的准确性至关重要。本研究采用的预测方法包括传统的统计模型如线性回归，以及更为先进的机器学习算法如支持向量机（SVM）、随机森林（Random Forest）和决策树（Decision Tree）。每种算法在处理光伏发电数据时都有其独特的优势和局限性。因此，本研究将探讨多种算法的应用，进行对比分析，以确定最适合当前数据特点的模型。

针对问题三，在建立预测模型后，评价模型性能的关键在于选择适当的评价指标。本研究采用的评价指标包括均方误差（MSE）、均方根误差（RMSE）、平均绝对误差（MAE）、以及决定系数（R^2）等。这些指标能够从不同角度评估模型的预测误差和拟合效果。然而，光伏发电的功率预测不仅需要考虑预测的准确性，还需要关注模型的稳定性和在极端情况下的表现。因此，本文将根据具体应用场景，选择最为合适的指标进行误差分析，以确保模型在实际应用中的可靠性和实用性。

综上所述，本文将系统性地研究光伏发电功率预测中的关键问题，并通过建立数学模型和应用先进的算法，提供一种能够在实际应用中有效指导电网调度、能源管理和光伏电站运维的预测方法。研究的结果将不仅为光伏发电领域提供理论支持，还能为实际应用提供指导，推动光伏发电技术的进一步发展和优化。

三、 基本假设

为简化问题，做出如下合理假设：

1） 假设所选数据集能够代表研究对象的整体特性，包括时间序列上的代表性和空间分布上的广泛性。
2） 假设影响光伏发电功率的主要环境因素已被识别并包含在数据集中，如光照强度、温度、降雨量、风速和风向等。
3） 假设所选用的机器学习模型能够适应数据的特性，并且能够有效捕捉数据中的模式和趋势。
4） 假设模型能够识别并赋予不同特征以适当的权重，以反映它们对光伏发电功率预测的影响大小。
5） 假设数据近似正态分布，允许使用均值、方差等参数来描述数据特征，并使得一些基于正态分布的算法和理论成立。
6） 假设所选用的性能评估指标能够全面反映模型预测的准确性和可靠性。

四、符号说明

符号	说明

SVM	支持向量机
Random Forest	随机森林
MAE	平均绝对误差
MSE	均方误差
RMSE	均方根误差
R^2	决定系数
IQR	四分法

五、模型建立与求解

5.1 问题一的分析与求解

5.1.1 原始数据集加载

原始数据集共有 49998 行 11 列，每列表示的分别是时间戳、光伏系统在一定时间内实际输出的有功电能量、电流的平均相位值、光伏发电功率、风速、天气温度、天气相对湿度、全球水平辐射、漫射水平辐射、风向、每日降雨量。

	Timestamp	Active Energy Delivered-Received (kWh)	Current Phase Average (A)	Active Power (kW)	Wind Speed (m/s)	Weather Temperature Celsius (℃)	Weather Relative Humidity (%)	Global Horizontal Radiation (W/m^2)	Diffuse Horizontal Radiation (W/m^2)	Wind Direction (Degrees)	Weather Daily Rainfall (mm)
0	2013-08-14 15:35:00	113970	11.464333	6.208334	3.100190	28.226471	17.152653	526.585205	54.478363	179.385696	NaN
1	2013-08-14 15:40:00	113971	11.152334	6.106200	3.415439	27.399916	17.834187	512.387695	55.947868	146.240540	NaN
2	2013-08-14 15:45:00	113971	10.898998	6.010433	2.373577	27.661219	17.747263	493.852539	51.699211	191.351410	NaN
3	2013-08-14 15:50:00	113972	10.557001	5.924666	3.515019	27.724470	17.451172	475.453247	48.139847	179.864182	NaN
4	2013-08-14 15:55:00	113972	10.284998	5.852333	3.287408	27.314009	17.803726	463.113190	51.068470	160.973099	NaN

图 1 原始数据集

5.1.2 数据清洗

数据清洗分为缺失值的处理与异常值的处理。通过检测发现原始数据集中光伏发电功率与每日降雨量的缺失值较多，分别为 23452 和 46495 项缺失值，具体情况如图 2 所示。对于光伏发电功率和日降雨量这两列数据，考虑到降雨量可能为零，以及在无光照条件下光伏发电无法进行，本研究选择用 0 填充这些列的缺失值。对于数据集中的其他列缺失值，通过计算相应列的均值来填充以保持数据的完整性。

变量	缺失值个数
Timestamp	0
Active Energy Delivered-Received (KWh)	0
Current Phase Average (A)	31
Active Power (KW)	23452
Wind Speed (m/s)	3

Weather Temperature Celsius (°C)	3
Weather Relative Humidity (%)	3
Global Horizontal Radiation (W/$\mathbf{m^2}$)	3
Diffuse Horizontal Radiation (W/ $\mathbf{m^2}$)	3
Wind Direction (Degrees)	3
Weather Daily Rainfall (mm)	46495

图 2 缺失值统计

对于异常值的处理，本研究首先基于数据属性的合理性对异常值进行了识别。本研究认为风向属性的取值范围应限定在 0 到 360 度之间，并且其余属性的取值范围应为非负。基于此观点识别到的异常值如图 3 所示。

变量	**异常值个数**
Active Energy Delivered-Received (KWh)	0
Current Phase Average (A)	0
Active Power (KW)	577
Wind Speed (m/s)	0
Weather Temperature Celsius (°C)	0
Weather Relative Humidity (%)	0
Global Horizontal Radiation (W/m)	0
Diffuse Horizontal Radiation (W/m)	0
Wind Direction (Degrees)	240
Weather Daily Rainfall (mm)	0

图 3 异常值统计

除此以外，本研究利用四分位数法（IQR）进一步识别异常值。该方法通过计算四分位数间距（IQR）来确定数据集中的异常值。通常，任何小于 Q1-1.5*IQR 或大于 Q3+1.5*IQR 的数据点被认为是异常值。用四分位数法识别到的异常值如图 4 所示。

对于所有识别出的异常值，本研究采取了删除处理，以确保数据集的准确性和可靠性。

变量	**异常值个数**
Active Energy Delivered-Received (KWh)	0
Current Phase Average (A)	0
Active Power (KW)	0
Wind Speed (m/s)	49
Weather Temperature Celsius (°C)	172
Weather Relative Humidity (%)	3055
Global Horizontal Radiation (W/$\mathbf{m^2}$)	0
Diffuse Horizontal Radiation (W/ $\mathbf{m^2}$)	3470
Wind Direction (Degrees)	0
Weather Daily Rainfall (mm)	953

图 4 四分位数法识别到的异常值统计

5.1.3 时间特征提取

不同月份的日照时间不同。夏季日照时间较长，而冬季日照时间较短。日照时间越长，光伏板接收到的太阳光越多，发电功率就越高。并且即使在同一天，不同时刻的太阳辐射强度也不同。早晨和傍晚太阳辐射较弱，中午时分太阳辐射最强，因此光伏发电功率在一天中会有波动。考虑到上述因素，本研究从时间戳中提取了时刻与月份这两个环境因素作为新的 x 变量，以助于模型更好地理解数据集的模式和趋势。

5.1.4 特征工程：影响因素的定量分析与选择

本研究首先绘制出了光伏发电功率随月份和时刻变化的折线图，如图 5、图 6 所示。图 5 显示了 2013 年 8 月至 2014 年 2 月的月平均光伏发电功率，从折线图可以看出，光伏发电功率在 8 到 10 月呈上升趋势并且在 10 月达到峰值，经过 10 月后大体呈现下降趋势并在 2 月达到最低值。整体来看，光伏发电功率在一年中的不同月份有显著差异。

图 6 显示了一天中不同时刻的光伏发电功率，从图表可以看出，光伏发电功率从 6 点到 12 点呈逐渐上升的趋势并在 12 点达到峰值，从 12 点到 18 点光伏发电功率逐渐下降。在夜间（从 18 点到次日的 6 点），光伏发电功率显著下降。整体来看，光伏发电功率随一天中太阳位置的变化而变化，呈现出明显的日周期性。

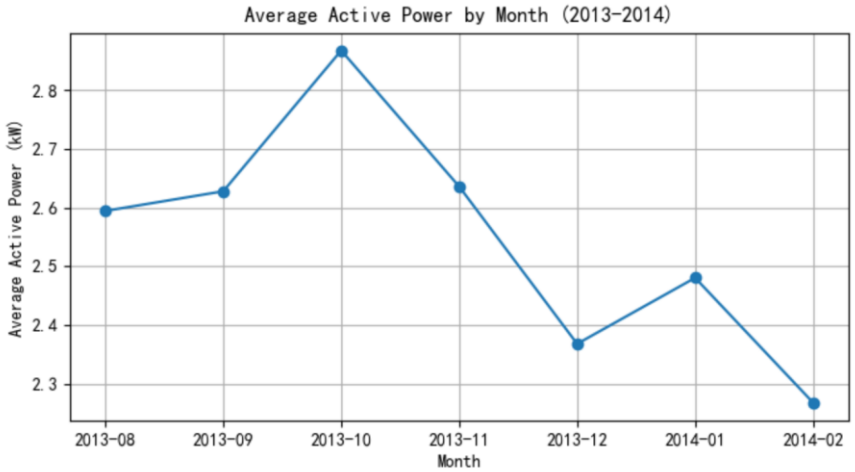


图 1 功率随月份变化折线图

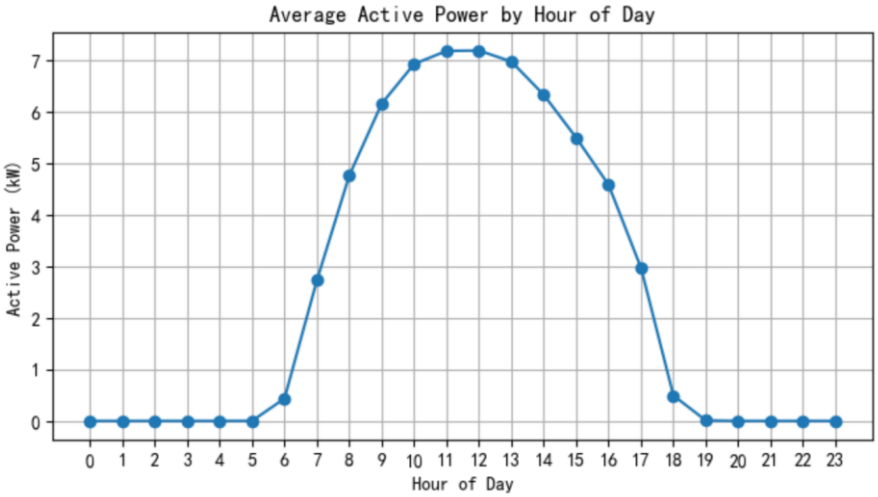


图 2 功率随时刻变化折线图

接下来本研究对月份、时刻以外的变量进行相关分析与重要程度排序，如图 7、图 8 所示。本研究选择皮尔逊相关系数与斯皮尔曼相关系数进行相关分析。皮尔逊相关系数侧重于两个随机变量之间的线性关系强度的统计度量，而斯皮尔曼相关系数考察的是两者单调关系的强度，不一定需要变量之间保持比例关系。按照正常的皮尔逊分析使用条件，数据集应符合正态分布方可使用。但在此题中因数据量过大所以直接使用，而后通过斯皮尔曼相关系数进行佐证与补充。

根据皮尔逊相关系数与斯皮尔曼相关系数可得电流的平均相位值、全球水平辐射、漫射水平辐射与光伏发电功率有极强相关性且为正相关；风速、天气温度与光伏发电功率有中相关性且为正相关，而天气相对湿度与光伏发电功率有中相关性且为负相关；而光伏系统在一定时间内实际输出的有功电能量、风向、每日降雨量与光伏发电功率无相关性。

因此本研究选取的用来预测光伏发电功率的变量有：电流的平均相位值、全球水平辐射、漫射水平辐射、风速、天气温度、天气相对湿度、月份、时刻。

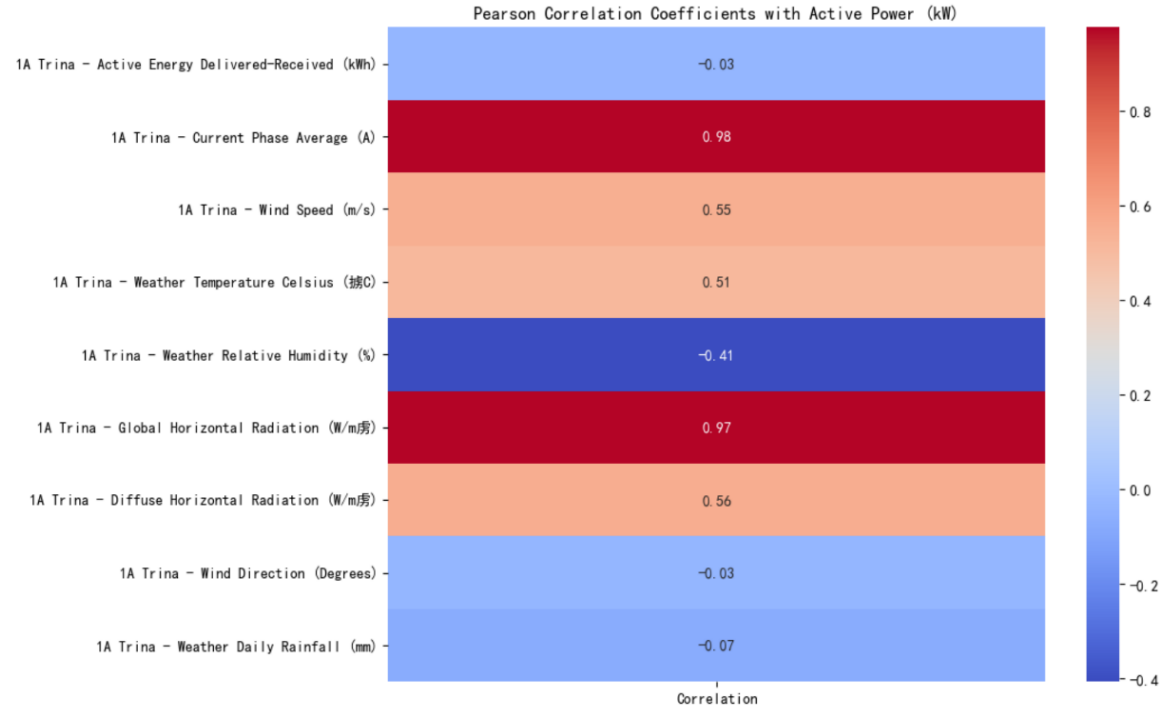


图 3 皮尔逊分析不同因素影响程度

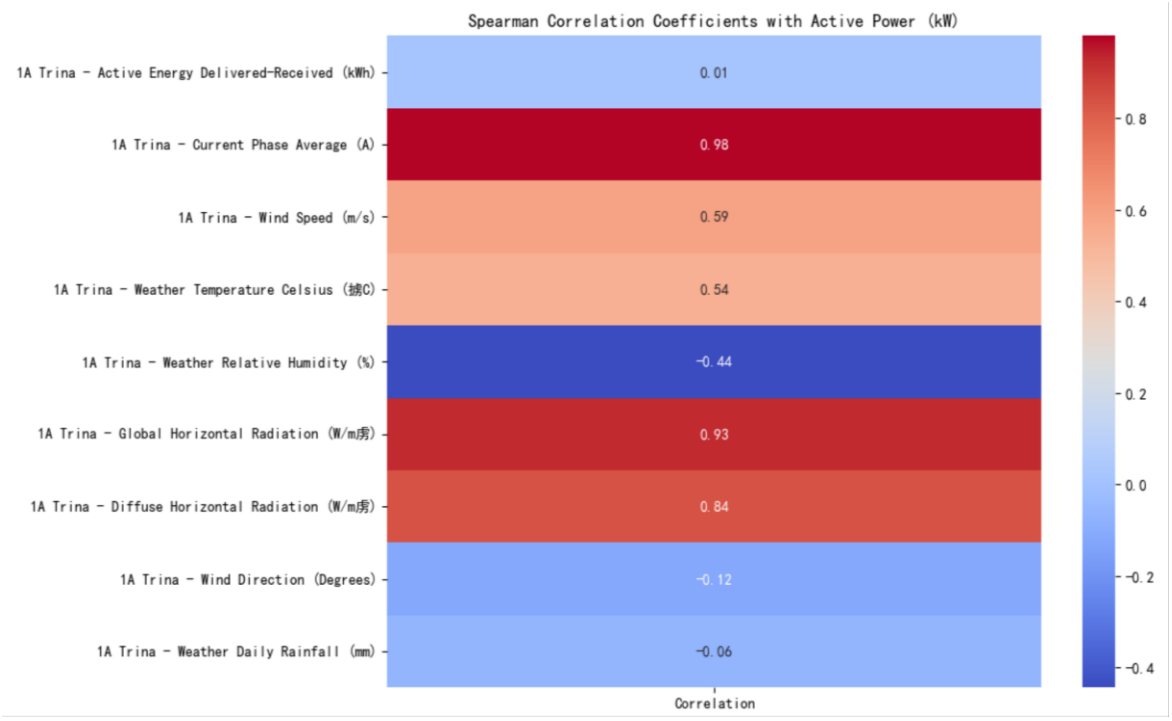


图 4 斯皮尔曼分析不同因素影响程度

除此以外，本研究还通过随机森林模型对以上变量进行特征重要性排序，如图 9 所示，根据图表分析可以得出电流的平均相位值对光伏发电功率影响程度最大。

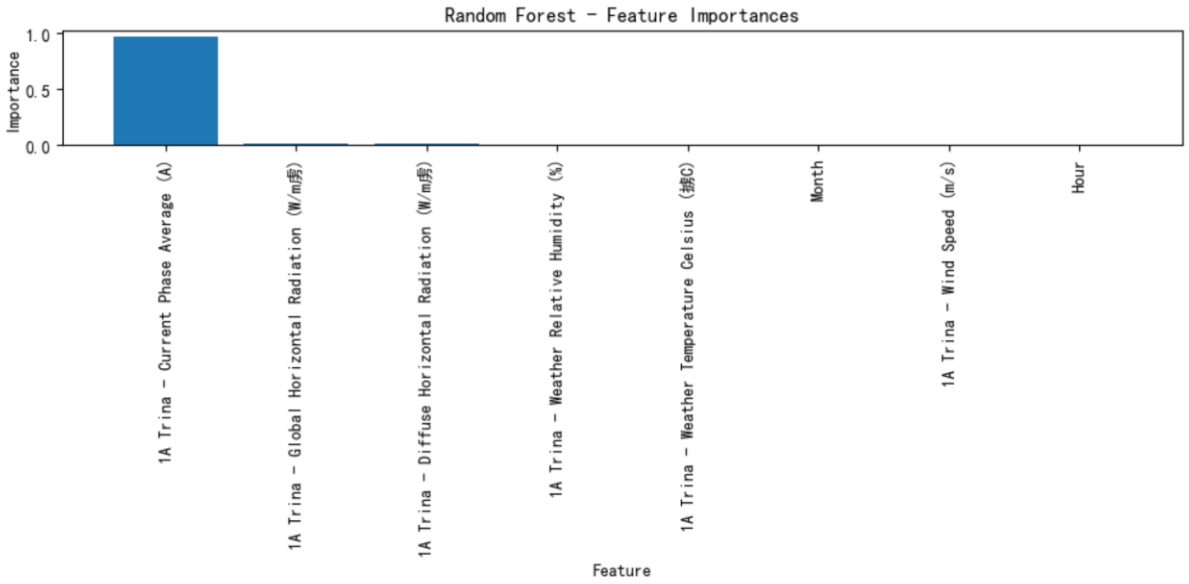


图 5 随机森林分析不同因素重要程度

5.2 问题二的分析与求解

5.2.1 模型选择与构建

本研究将提供的数据集按照 8:2 的比例划分为训练集和测试集。首先使用的是较为简单的线性回归模型，随后用一系列机器学习模型进行预测分析，包括决策树、随机森林、支持向量机模型。

5. 2. 2 模型训练与验证

本研究将实际值与测试集的预测结果绘制成折线图。因数据过多，为使可视化更为清晰简洁易懂，本研究选出测试集预测结果的 40 分之一作为观测目标。其中蓝色折线代表真实值，橙色折线代表测试集的预测值，通过两种颜色的折线图对比可以得到预测结果的可视化体现。

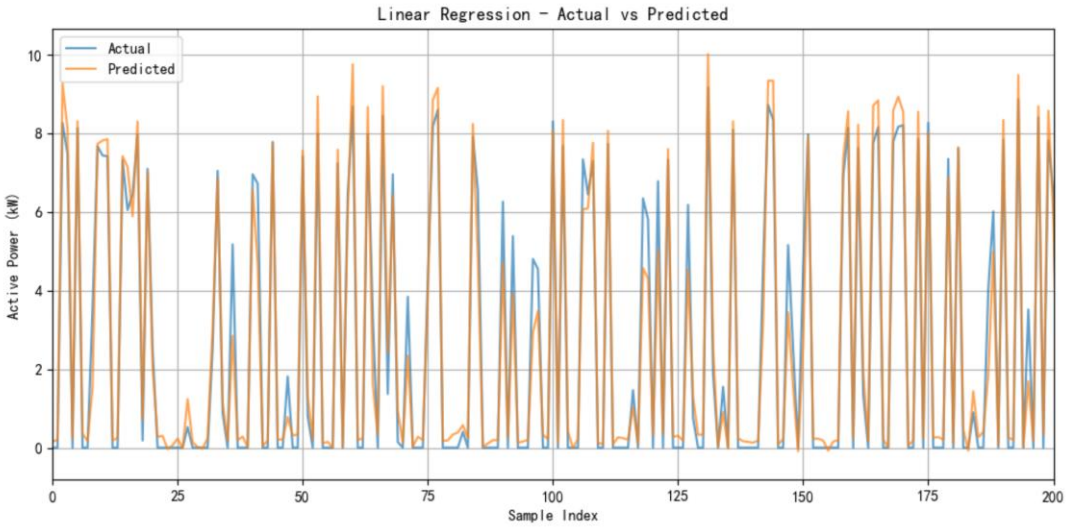


图 10 线性回归模型预测效果（测试集）

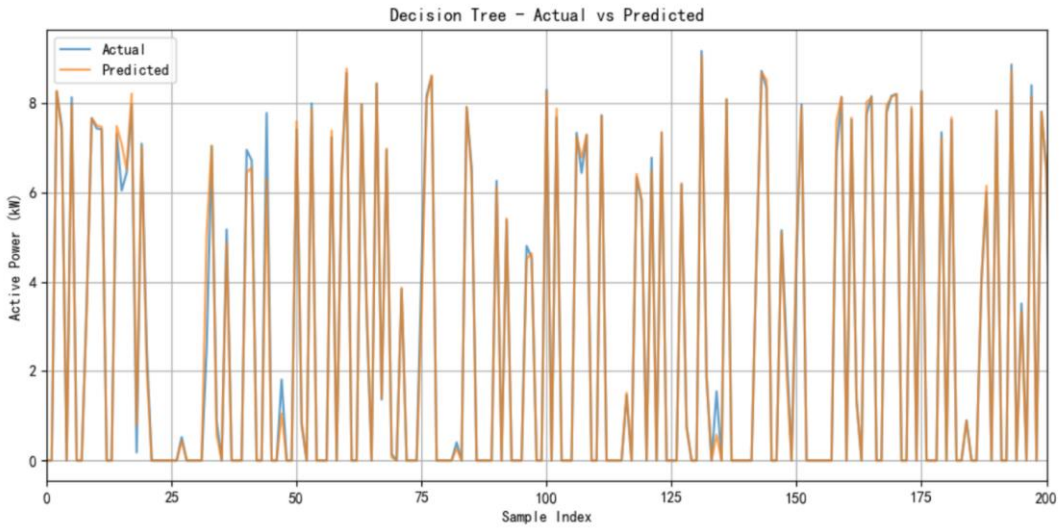


图 11 决策树模型预测效果（测试集）

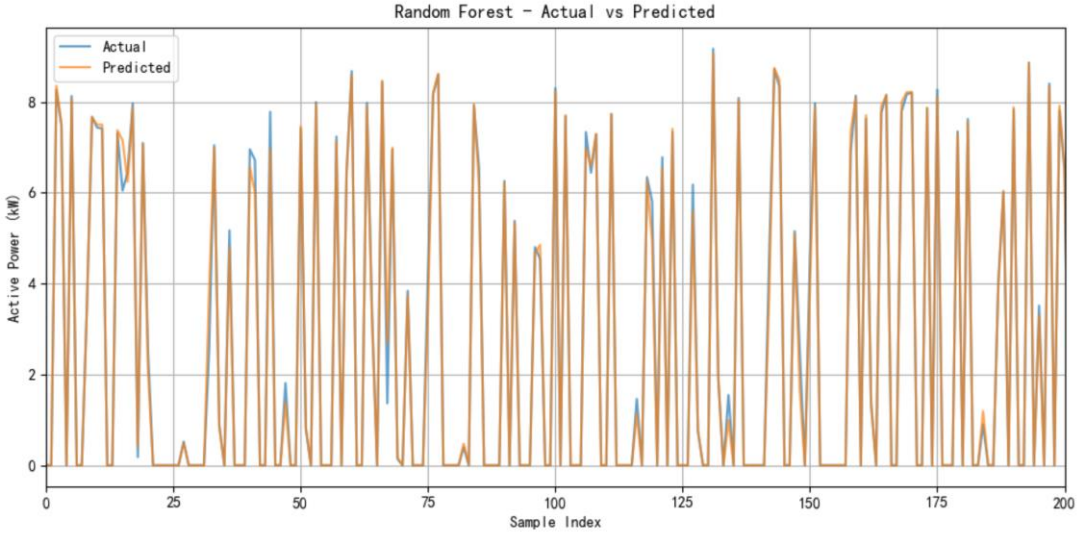


图 6 随机森林模型预测效果（测试集）

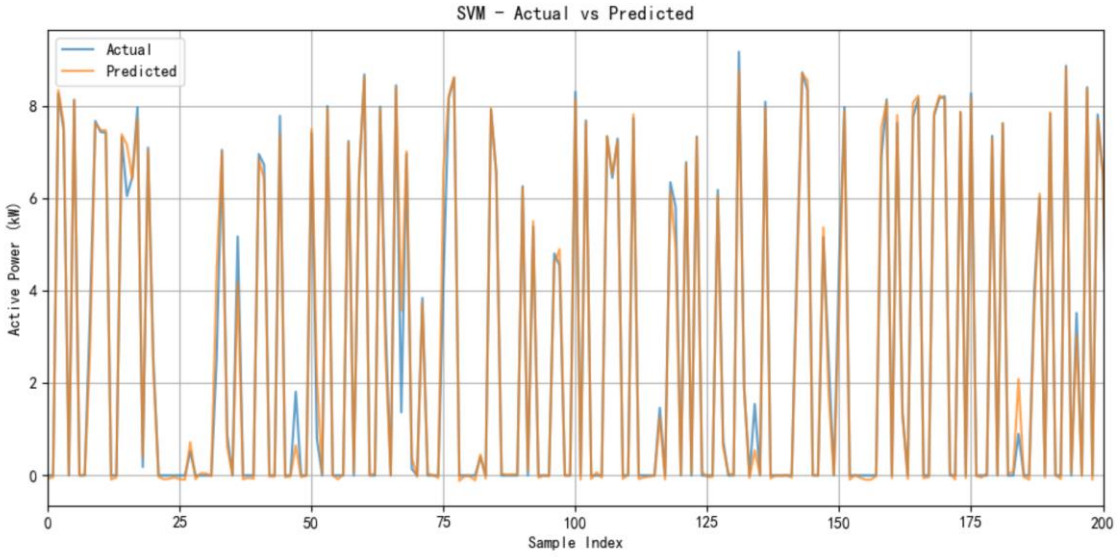
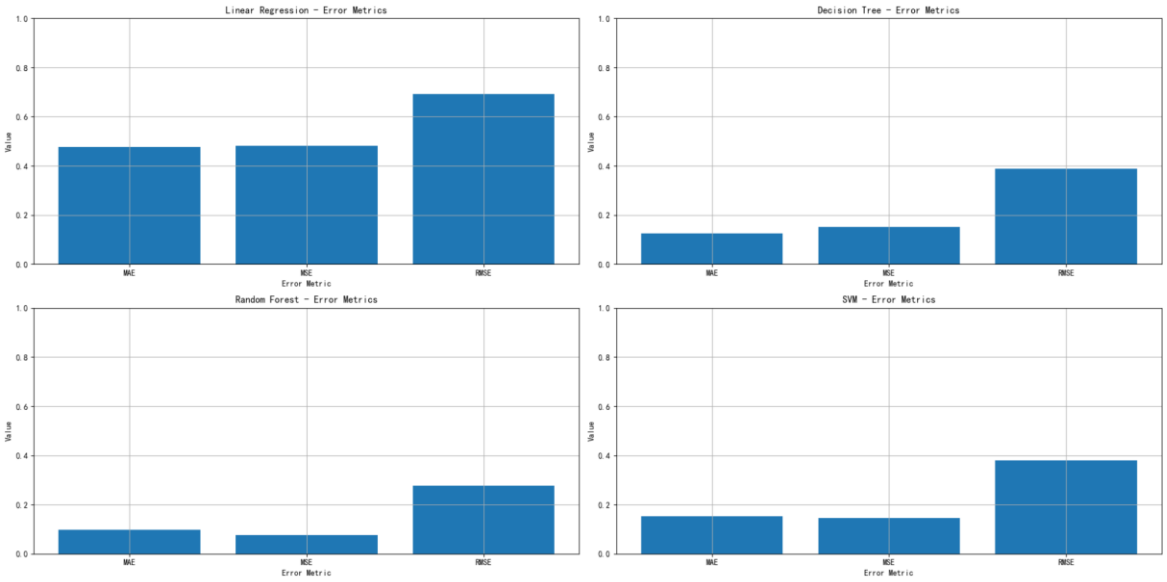


图 7 支持向量机模型预测效果（测试集）

5.3 问题三的分析与求解



图表 8 不同模型误差分析柱状图

本文用到的评价指标主要为:

（1）均方误差(Mean Squared Error, MSE): MSE 是实际值与预测值误差平方的平均值,其公式为:

$$MSE=\frac{1}{n}*\sum(actual-prediction)^2$$

其中 n 为样本数量,actual 为实际值,prediction 为预测值。

（2）平均绝对误差(Mean Absolute Error,MAE):

MAE 是实际值与预测值误差绝对值的平均值,其公式为:

$$MAE=\frac{1}{n}*\sum|actual-prediction|$$

(3) R 方得分(R^2 score):

R^2 score 是预测值与实际值的相关系数的平方,表示模型解释了多少比例的数据变异,其公式为:

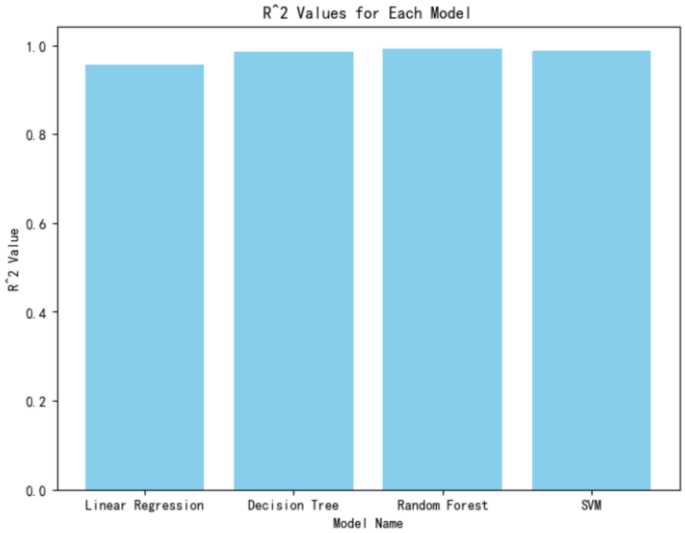
$$R^2=1-\frac{\sum(actual-precdition)^2}{\sum(actual-mean(actual)^2)}$$

因评判指标中的 MAE、MSE、RMSE 是值越小代表预测结果越好而 R^2 越接近 1 则代表结果更为准确。从而根据不同模型的指标图可以得到随机森林，支持向量机，决策树均有较为不错的预测结果。下图为各模型的具体误差指标值。

	Linear Regression Errors	Decision Tree Errors	Random Forest Errors	SVM Errors
MAE	0.4773100565290461	0.12450150156737376	0.09680546791069398	0.15288648850824418
MSE	0.4806219693419882	0.15034778987301173	0.07652846019463734	0.14430806629121193
RMSE	0.6932690454231951	0.38774706945767073	0.27663777795999839	0.37987901533410 86

R^2	0.9557185641925107	0.9861479157617898	0.9929491568972713	0.9867043772827824

图表 9 不同模型误差分析具体数值



图表 10 不同模型 R^2 柱状图

六、模型评价与应用

6.1 模型的优点

在本研究中构建的光伏发电功率预测模型具有多方面的优点。首先，模型通过综合分析多种环境因素对光伏发电功率的影响，捕捉了各因素之间的复杂关系，从而提高了预测的准确性。其次，模型使用了多种先进的机器学习算法，如线性回归，决策树，支持向量机（SVM）和随机森林（Random Forest），这些算法在处理非线性和高维数据方面表现出色，能够有效应对光伏发电数据的复杂性和波动性。此外，通过多模型融合技术，模型能够进一步提升预测性能，增强了模型的稳健性和适应性。最后，模型具备较强的通用性和可扩展性，可以适用于不同地域和气候条件下的光伏电站，为实际应用提供了有力的支持。

6.2 模型的缺点以及改进方向

尽管本研究中的模型在光伏发电功率方面已经表现出优异的预测能力，但仍存在一些需要改进之处。首先，模型的复杂性较高，在划分训练集与测试集时用到了许多训练资源进行计算，消耗较大。不适用于生活中天气具有一定实时性的场景。因此，可以考虑在未来研究中引入其他高效便捷的算法或优化现有算法的相关性能，以降低计算成本。其次，模型的性能在极端天气条件下可能不如常规条件下稳定，这可能是由于训练数据集中极端天气样本较少所致。因此，未来可以通过扩展训练数据集，增加极端天气条件下的数据，或使用数据增强技术来提高模型的鲁棒性【5】。此外，模型对输入数据的质量和完整性有较高要求，而在本组实验中，对于缺失数据与异常数据仅进行了删除处理可能导致预测产生误差。可以进一步研究更为有效的预处理方法，如数据插补和降噪技术，以提升模型在数据质量较差情况下的表现。

6.3 模型的推广与应用(待查资料)

本研究所构建的光伏发电功率预测模型具有广泛的推广和应用潜力。首先，该模型可以应用于光伏电站的实时发电功率预测，为电网调度提供可靠的依据，帮助电力公司更好地平衡供需关系，提升电力系统的稳定性和运行效率。其次，在能源管理方面，该模型可以为光伏电站运营商提供发电量的精准预测，从而优化能源储存和分配策略，降低运营成本。此外，该模型还可以应用于光伏发电的长期规划和投资决策，预测未来发电潜力【6】，帮助企业和政府制定更加科学合理的投资和政策规划。通过与其他能源预测模型的结合，该模型也可以推广应用于混合能源系统的综合预测和优化，为实现更高效的能源利用和可持续发展提供技术支持。

最后在未来，可以使用光伏并网发电系统对电网进行无功补偿和功率因数校正。同时将光伏并网发电系统的大规模使用与远程数据监控联系在一起，并结合光伏并网发电系统的经济运行、社会效益和环境效益开发实用的光伏并网发电系统的测控系统的软件【7】。

七、参考文献

【1】臧鹏发;王珂琪;张中伟;赵中阳;姚龙超;翁卫国;吴学成;郑成航;高翔. 基于多特征提取的超短期光伏发电功率预测研究. 激光与光电子学进展，工程科技Ⅱ辑，2024.

【2】牟震江,涂超. 四川省县域人均 GDP 空间关联性探索性空间数据分析. 中南农业科技, 2023.

【3】汪洋. 基于深度强化学习的数据探索性会话自动生成. 信息科技, 2024. DOI：10.19850/j.cnki.2096-4706.2024.04.014.

【4】杨阳. 基于光子增强热电子发射（PETE）的全固态高温太阳能电池技术研究. 中国科学院研究生院, 2016.

【5】罗钢. 电网可用输电能力的计算方法研究. 华中科技大学, 2015.

【6】姚玉璧;郑绍忠;杨扬;张民;赵继锋;李强. 中国太阳能资源评估及其利用效率研究进展与展望. 兰州资源环境职业技术大学/甘肃省气候资源利用与防灾减灾重点实验室，中国气象局兰州干旱气象研究所，2022. DOI：10.19912/j.0254-0096.tynxb.2022-0141.

【7】赵为. 太阳能光伏并网发电系统的研究. 合肥工业大学, 2003.

八、附录（代码）

```
#导入需要的库
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
from matplotlib import rcParams
plt.rcParams['font.family']=['sans-serif']
plt.rcParams['font.sans-serif']=['SimHei']
plt.rcParams['axes.unicode_minus']=False
import datetime
import time

#加载数据集
df= pd.read_csv("C题数据.csv",encoding='gbk')
df.head()

#查看数据集基本信息
print(df.shape)
print(df.info())
print(df.isnull().sum())

#均值填充缺失值
columns_to_fill = ['1A Trina - Current Phase Average (A)', '1A Trina - Wind Speed (m/s)', '1A Trina - Weather Temperature Celsius (摄C)',
                   '1A Trina - Weather Relative Humidity (%)','1A Trina - Global Horizontal Radiation (W/m虏)',
                   '1A Trina - Diffuse Horizontal Radiation (W/m虏)','1A Trina - Wind Direction (Degrees)']
df[columns_to_fill] = df[columns_to_fill].fillna(df[columns_to_fill].mean())

# 0填充缺失值
columns_to_fill = ['1A Trina - Active Power (kW)', '1A Trina - Weather Daily Rainfall (mm)']
df[columns_to_fill] = df[columns_to_fill].fillna(0)

#查看数据集中负数个数
#选择数据集中的所有数值列
numeric_cols = df.select_dtypes(include=[np.number]).columns

```

```
# 初始化一个字典来存储每列小于0的个数
negative_counts = {}

# 遍历数值列
for column in numeric_cols:
    # 计算小于0的个数
    count_negative = (df[column] < 0).sum()
    # 将结果存储到字典中
    negative_counts[column] = count_negative

# 打印每列小于0的个数
for column, count in negative_counts.items():
    print(f"{column} 中小于0的个数: {count}")

#查看风向异常值，即小于0大于360
out_of_range = (df['1A Trina - Wind Direction (Degrees)'] < 0) | (df['1A Trina - Wind Direction (Degrees)'] > 360)

# 计算异常值的个数
outlier_count = out_of_range.sum()

# 打印异常值的个数
print(f"风向异常值个数（小于0度或大于360度）: {outlier_count}")

#删除异常值
for column in numeric_cols:
    # 选择非负数的数据
    df = df[df[column] >= 0]

#用四分位数法（IQR）识别并处理异常值
from scipy.stats import mstats

# 初始化一个字典来存储每列的异常值个数
outliers_count = {}

# 遍历DataFrame的每一列
for column in numeric_cols:
    # 计算四分位数
    Q1 = mstats.mquantiles(df[column].dropna(), 0.25)[0]
    Q3 = mstats.mquantiles(df[column].dropna(), 0.75)[0]
```

```
    # 计算IQR
    IQR = Q3 - Q1
    # 计算异常值的界限
    lower_bound = Q1 - 1.5 * IQR
    upper_bound = Q3 + 1.5 * IQR

    # 识别异常值
    outliers = df[(df[column] < lower_bound) | (df[column] > upper_bound)]

    # 计算异常值的数量
    outlier_count = outliers[column].count()
    outliers_count[column] = outlier_count

    # 打印每列的异常值个数
    print(f"Column: {column}, Outliers count: {outlier_count}")

    # 删除异常值
    df = df[(df[column] >= lower_bound) & (df[column] <= upper_bound)]
print(df.shape)
print(df.isnull().sum())

#分析月份与时刻对光伏发电的影响
#月份
# 确保数据集中的日期时间列被正确解析
df['Timestamp'] = pd.to_datetime(df['Timestamp'])

# 将Timestamp转换为年份和月份
df['YearMonth'] = df['Timestamp'].dt.to_period('M')

# 计算2013年和2014年每个月的光伏发电功率平均值
avg_power_by_month = df[df['YearMonth'].dt.year.isin([2013, 2014])].groupby('YearMonth')['1A Trina - Active Power (kW)'].mean()

# 绘制每个月光伏发电功率平均值的折线图
plt.figure(figsize=(8, 4))
plt.plot(avg_power_by_month.index.astype(str), avg_power_by_month.values, marker='o')
plt.title('Average Active Power by Month (2013-2014)')
plt.xlabel('Month')
plt.ylabel('Average Active Power (kW)')
```

```
plt.grid(True)
plt.show()

#时刻
# 将Timestamp转换为小时
df['Hour'] = df['Timestamp'].dt.hour

# 计算一天24小时内光伏发电功率的平均值
avg_power_by_hour = df.groupby('Hour')['1A Trina - Active Power (kW)'].mean()

# 绘制一天24小时内光伏发电功率变化的折线图
plt.figure(figsize=(8, 4))
plt.plot(avg_power_by_hour.index, avg_power_by_hour.values, marker='o')
plt.title('Average Active Power by Hour of Day')
hours_str = [f"{hour}:00" for hour in avg_power_by_hour.index]
plt.xlabel('Hour of Day')
plt.ylabel('Active Power (kW)')
plt.xticks(range(24))  # 确保x轴显示所有小时
plt.grid(True)
plt.show()
print(df.info())

#相关分析
#皮尔逊相关系数
from scipy.stats import pearsonr

# 选择要计算相关系数的列，排除'Timestamp', 'month','moment'和‘Hour’
columns_to_analyze = [col for col in df.columns if col not in ['Timestamp', 'YearMonth', 'Hour','Month']]

active_power_correlation = {}

# 计算光伏发电功率其他列的相关系数
for col in columns_to_analyze:
    if col != '1A Trina - Active Power (kW)':
            corr, _ = pearsonr(df['1A Trina - Active Power (kW)'], df[col])
            active_power_correlation[col] = corr

# 将相关系数转换为DataFrame，并绘制热图
correlation_matrix = pd.DataFrame(active_power_correlation, index=['Correlation']).T
```

```
plt.figure(figsize=(10, 8))
sns.heatmap(correlation_matrix, annot=True, fmt=".2f", cmap='coolwarm')
plt.title('Pearson Correlation Coefficients with Active Power (kW)')
plt.show()

#斯皮尔曼等级相关系数
from scipy.stats import spearmanr

active_power_correlation_spearman = {}

# 计算'1A Trina - Active Power (kW)' 与其他列的斯皮尔曼相关系数
for col in columns_to_analyze:
    if col != '1A Trina - Active Power (kW)':
            corr, _ = spearmanr(df['1A Trina - Active Power (kW)'], df[col])
            active_power_correlation_spearman[col] = corr

# 将相关系数转换为DataFrame，并绘制热图
correlation_matrix_spearman = pd.DataFrame(active_power_correlation_spearman, index=['Correlation']).T
plt.figure(figsize=(10, 8))
sns.heatmap(correlation_matrix_spearman, annot=True, fmt=".2f", cmap='coolwarm')
plt.title('Spearman Correlation Coefficients with Active Power (kW)')
plt.show()

df['Month'] = df['Timestamp'].dt.month
print(df.info())
#创建新的df
df = df.drop(df.columns[[0,1,9,10,11]], axis=1)
print(df.info())

#导入机器学习相关的库
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.ensemble import RandomForestRegressor

# 8: 2划分训练集和测试集
X = df.drop(columns=['1A Trina - Active Power (kW)'])
y = df['1A Trina - Active Power (kW)']
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

```
# 标准化数据
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

# 建立和训练随机森林模型
model = RandomForestRegressor(random_state=42)
model.fit(X_train_scaled, y_train)

# 获取特征重要性
importances = model.feature_importances_
indices = np.argsort(importances)[::-1]
features = X.columns
plt.figure(figsize=(10, 5))
plt.title('Random Forest - Feature Importances')
plt.bar(range(len(importances)), importances[indices], align='center')
plt.xticks(range(len(importances)), features[indices], rotation=90)
plt.xlabel('Feature')
plt.ylabel('Importance')
plt.tight_layout()
plt.show()
print("随机森林模型的特征重要性排序：")
for i in indices:
    print(f"{features[i]}: {importances[i]}")

#导入用来预测的机器学习模型
from sklearn.linear_model import LinearRegression
from sklearn.tree import DecisionTreeRegressor
from sklearn.svm import SVR
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score

models = {
    'Linear Regression': LinearRegression(),
    'Decision Tree': DecisionTreeRegressor(random_state=42),
    'Random Forest': RandomForestRegressor(random_state=42),
    'SVM': SVR()
}

# 存储预测结果
```

```
predictions = {}
errors = {}

for model_name, model in models.items():
    model.fit(X_train_scaled, y_train)
    y_pred = model.predict(X_test_scaled)
    predictions[model_name] = y_pred
    errors[model_name] = {
        'MAE': mean_absolute_error(y_test, y_pred),
        'MSE': mean_squared_error(y_test, y_pred),
        'RMSE': np.sqrt(mean_squared_error(y_test, y_pred)),
        'R^2': r2_score(y_test, y_pred)
    }

# 可视化预测结果
plt.figure(figsize=(20, 10))

for i, (model_name, y_pred) in enumerate(predictions.items()):
    plt.subplot(2, 2, i + 1)
    plt.plot(y_test.values, label='Actual', alpha=0.7)
    plt.plot(y_pred, label='Predicted', alpha=0.7)
    plt.title(f'{model_name} - Actual vs Predicted')
    plt.xlabel('Sample Index')
    plt.ylabel('Active Power (kW)')
    plt.legend()
    plt.grid()
    plt.xlim(0, 200)

plt.tight_layout()
plt.show()

# 绘制误差分布图
plt.figure(figsize=(20, 10))

for i, (model_name, error) in enumerate(errors.items()):
    plt.subplot(2, 2, i + 1)
    plt.bar(['MAE', 'MSE', 'RMSE'],
            [error[metric] for metric in ['MAE', 'MSE', 'RMSE']])
    plt.title(f'{model name} - Error Metrics')
```

```
    plt.xlabel('Error Metric')
    plt.ylabel('Value')
    plt.grid()
    plt.ylim(0, 1)

plt.tight_layout()
plt.show()
for model_name, error in errors.items():
    print(f'{model_name} Errors:')
    for error_metric, value in error.items():
        print(f'{error_metric}: {value}')
    print()

#绘制每个模型对应的r^2值

#提取每个模型对应的值
r2_values = [errors[model]['R^2'] for model in errors]

# 模型名称作为X轴的标签
model_names = list(errors.keys())

# 创建条形图
plt.figure(figsize=(8, 6))  # 设置图形大小
plt.bar(model_names, r2_values, color='skyblue')  # 创建条形图，使用skyblue颜色

# 设置图表标题和坐标轴标签
plt.title('R^2 Values for Each Model')
plt.xlabel('Model Name')
plt.ylabel('R^2 Value')

# 显示图形
plt.show()
```